

TALLINNA TEHNIKAÜLIKOOL

Infotehnoloogia teaduskond

Greteli Mittal IAIB233041

Maria Kristina Andranikyan IAIB2

Keelemudelipõhine ajaleheartiklite eraldamine ja temaatiline analüüs

Bakalaureusetöö

Juhendaja: Innar Liiv

PhD

Tallinn 2026

Autorideklaratsioon

Kinnitame, et oleme koostanud antud lõputöö iseseisvalt ning seda ei ole kellegi teise poolt varem kaitsmisele esitatud. Kõik töö koostamisel kasutatud teiste autorite tööd, olulised seisukohad, kirjandusallikatest ja mujalt pärinevad andmed on töös viidatud.

Autorid: Greteli Mittal ja Maria Kristina Andranikyan

15.03.2026

Annotatsioon

[ANNOTATSIOONI TEKST LÄHEB SIIA]

Lõputöö on kirjutatud eesti keeles ning sisaldab teksti 9 leheküljel, 7 peatükki, 2 joonist, 1 tabel.

Abstract

Language model-based newspaper article extraction and thematic analysis

[YOUR TEXT GOES HERE]

The thesis is in Estonian and contains 9 pages of text, 7 chapters, 2 figures, 1 table.

Lühendite ja mõistete sõnastik

API	Rakendusliides (<i>Application Programming Interface</i>)
CPU	Keskseade (<i>Central Processing Unit</i>)
IDE	Integreeritud programmeerimiskeskkond (<i>Integrated Development Environment</i>)
OCR	Optiline märgituvastus (<i>Optical Character Recognition</i>)
RaRa	Eesti Rahvusraamatukogu
Token	Mõiste
DIGAR	Eesti Rahvusraamatukogu digitaalarhiiv

Sisukord

1	Sissejuhatus.....	9
2	Taust.....	12
2.1	First Section of the First Chapter.....	12
2.1.1	First Subsection	12
2.2	Second Section of the First Chapter.....	12
3	Metoodika ja andmestik	13
4	Katsed ja hindamismeetodid	14
5	Andmeanalüüs ja demonstreerimine	15
6	Tulemused ja järeldused	16
7	Kokkuvõte.....	17
	Kasutatud kirjandus	18
	Lisa 1 – Lihtlitsents lõputöö reprodutseerimiseks ja lõputöö üldsusele kättesaadavaks tegemiseks.....	19
	Lisa 2 – Something	20
	Lisa 3 – Something Else	21

Jooniste loetelu

Joonis 1. An image of TalTech logo.....	9
Joonis 2. Side-by-side images of Tux: (a) on a white background, (b) on a black background.....	10

Tabelite loetelu

Tabel 1. A table with some requirements.....	11
--	----

1 Sissejuhatus

Some basic ways to manipulate text are *italics* and **bold**.

One can reference Figures (see Figure 1 for example) as well as cite references which are defined in the *references.bib* file [1], [2] .



Joonis 1. An image of TalTech logo.


The *Bibliography*, *List of Figures*, and *List of Tables* are automatically generated, with references, figures, and tables updated as needed. Unused citations won't appear, and numbering follows the order of appearance. One can create an itemized list:

- item a
- item b
- ...

Or enumerate them:

1. item x
2. item y
3. ...

A pair of side-by-side images can be seen in Figure 2. Each image can also be referenced individually; for instance, refer to Figure 2a for the first image.



Joonis 2. Side-by-side images of Tux: (a) on a white background, (b) on a black background.

Using Part Labels

Labels in the format `\label{chapter:<part_name>}` are used to categorize chapters into specific parts of the thesis structure. They play an important role in maintaining the document's structure and validating its compliance with expected ratios for each section.

■ Allowed Labels:

- `chapter:introduction` - For the **Introduction** section (less than 10% of the thesis).
- `chapter:method` - For the **Methodology** section (up to 20%).
- `chapter:results` - For the **Results** section (30–40%).
- `chapter:discussion` - For the **Discussion and Analysis** section (30–40%).
- `chapter:summary` - For the **Summary** section (less than 0.5 pages).

■ **Purpose:** These labels enable automated tools to check if each part of your thesis conforms to the required word count ratios.

■ **Usage:** Add the appropriate label to the `\chapter` command for each chapter in your document.

■ **Subdividing a Part into Multiple Chapters:** If a single part (e.g., **Discussion**) is split into multiple chapters, ensure the main part label remains consistent, and additional identifiers can be appended to distinguish chapters. For instance:

- `\label{chapter:discussion-analysis}` for an analysis chapter.
- `\label{chapter:discussion-discussion}` for the primary discussion.
- `\label{chapter:discussion-conclusions}` for conclusions.

Only the main part (e.g., `chapter:discussion`) is relevant for validation and ratio

calculations; the suffixes (e.g., -analysis, -discussion, -conclusions) are for your internal organization and clarity.

Here, you can use `\blindtext` to see how the table continues on the next page. This command generates dummy text that can help you visualize the layout of your document. Uncomment the line above to add filler text.

A table with three columns can be seen in Table 1.

Tabel 1. A table with some requirements.

Nr	Requirement	Weight
1	Price	High
2	Variety	Middle
3	Support	Low

We can use variables set in the *main.tex* file to render values like our title (Language model-based newspaper article extraction and thematic analysis) or supervisor names (**Supervisor:** Innar Liiv, **Co-supervisor:** [Co-Supervisor's Name]).

2 Taust

This is the first real chapter of this thesis. Other chapters can be easily referenced, for example the introduction can be found as Chapter 1. Sections and/or subsections need to be labeled before one can reference them. See Section 2.2 for an example.

2.1 First Section of the First Chapter

Some text in the first section.

2.1.1 First Subsection

As well as some text in this subsection.

First Subsubsection

The Table of Contents only goes 3 layers deep (Chapter - Section - Subsection) so this subsubsection is not seen there.

2.2 Second Section of the First Chapter

3 Metoodika ja andmestik

One of the best resources for $\text{\LaTeX}$ basics, and advanced constructs, is the $\text{\LaTeX}$ wikibook¹. Of course fellow students, colleagues and a good internet search using your favorite search engine can do wonders if you're stuck.

¹To be found at <http://en.wikibooks.org/wiki/LaTeX/>

4 Katsed ja hindamismeetodid

5 Andmeanalüüs ja demonstreerimine

6 Tulemused ja järeldused

7 Kokkuvõte

Kasutatud kirjandus

- [1] Paul Kocher *et al.* „Spectre Attacks: Exploiting Speculative Execution“. Teoses: *40th IEEE Symposium on Security and Privacy (S&P'19)*. 2019.
- [2] L. Masinter. *Hyper Text Coffee Pot Control Protocol (HTCPCP/1.0)*. [Accessed: 24-05-2019].
URL: <https://tools.ietf.org/html/rfc2324>.

Lisa 1 – Lihtlitsents lõputöö reprodutseerimiseks ja lõputöö üldsusele kättesaadavaks tegemiseks¹

Meie, Greteli Mittal ja Maria Kristina Andranikyan

1. Anname Tallinna Tehnikaülikoolile tasuta loa (lihtlitsentsi) enda loodud teose “Keel mudelipõhine ajaleheartiklite eraldamine ja temaatiline analüüs”, mille juhendaja on Innar Liiv
 - 1.1. reprodutseerimiseks lõputöö säilitamise ja elektroonse avaldamise eesmärgil, sh Tallinna Tehnikaülikooli raamatukogu digikogusse lisamise eesmärgil kuni autoriõiguse kehtivuse tähtaja lõppemiseni;
 - 1.2. üldsusele kättesaadavaks tegemiseks Tallinna Tehnikaülikooli veebikeskonna kaudu, sealhulgas Tallinna Tehnikaülikooli raamatukogu digikogu kaudu kuni autoriõiguse kehtivuse tähtaja lõppemiseni.
2. Oleme teadlikud, et käesoleva lihtlitsentsi punktis 1 nimetatud õigused jäävad alles ka autoritele.
3. Kinnitame, et lihtlitsentsi andmisega ei rikuta teiste isikute intellektuaalomandi ega isikuandmete kaitse seadusest ning muudest õigusaktidest tulenevaid õigusi.

15.03.2026

¹Lihtlitsents ei kehti juurdepääsupiirangu kehtivuse ajal vastavalt üliõpilase taotlusele lõputööle juurdepääsupiirangu kehtestamiseks, mis on allkirjastatud teaduskonna dekaani poolt, välja arvatud ülikooli õigus lõputööd reprodutseerida üksnes säilitamise eesmärgil. Kui lõputöö on loonud kaks või enam isikut oma ühise loomingu tegevusega ning lõputöö kaas- või ühisautor(id) ei ole andnud lõputööd kaitsvale üliõpilasele kindlaksmääratud tähtjaks nõusolekut lõputöö reprodutseerimiseks ja avalikustamiseks vastavalt lihtlitsentsi punktidele 1.1. ja 1.2, siis lihtlitsents nimetatud tähtaja jooksul ei kehti.

Lisa 2 – Something

```
<!DOCTYPE html>  
<html>  
<body>  
  
<h1>Example Title </h1>  
  
<p>Some text here </p>  
  
</body>  
</html>
```

Lisa 3 – Something Else

Pythagorean theorem

$$x^n + y^n = z^n \tag{1}$$

Normal distribution

$$P(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2} \tag{2}$$